

A solução: ELU com inicialização ortogonal calibrada

O ganho sai de $E[f(z)^2]$ — e a camada 1 é a exceção, porque nela entra o dado, não $f(z)$

A ATIVAÇÃO

$$f(x) = \begin{cases} x & \text{se } x > 0 \\ e^x - 1 & \text{se } x \leq 0 \end{cases}$$

elemento a elemento, sem parâmetros. Derivada não nula em todo o eixo — inclusive no lado negativo.

$$E[f(z)^2] = 0,645$$

com $z \sim N(0, 1)$, estimado uma vez com 10^6 amostras

A INICIALIZAÇÃO

$$s^2 = \frac{1}{\text{fan_in} \cdot E[f(z)^2]}$$

$$\text{impondo } \text{Var}(z') = \text{fan_in} \cdot s^2 \cdot E[f(z)^2] = 1$$

A matriz é preenchida com `torch.nn.init.orthogonal_`, e não com um sorteio gaussiano: a fórmula acima fixa apenas a média dos valores singulares, enquanto a ortogonal fixa todos eles em 1.

camada 1

ganho = 1,0

Nela entra o dado padronizado, com $E[x^2] = 1$, e não $f(z)$.

camadas 2 a L

ganho = $1/\sqrt{E[f^2]} \times a$

atenuação $a = 0,85$ se $L \leq 8$
 $a = 0,70$ se $L > 8$

```
ganho = 1.0 if camada == 1 else atenuacao * (1.0 / E_f2) ** 0.5  
torch.nn.init.orthogonal_(W, gain=ganho); b.zero_()
```