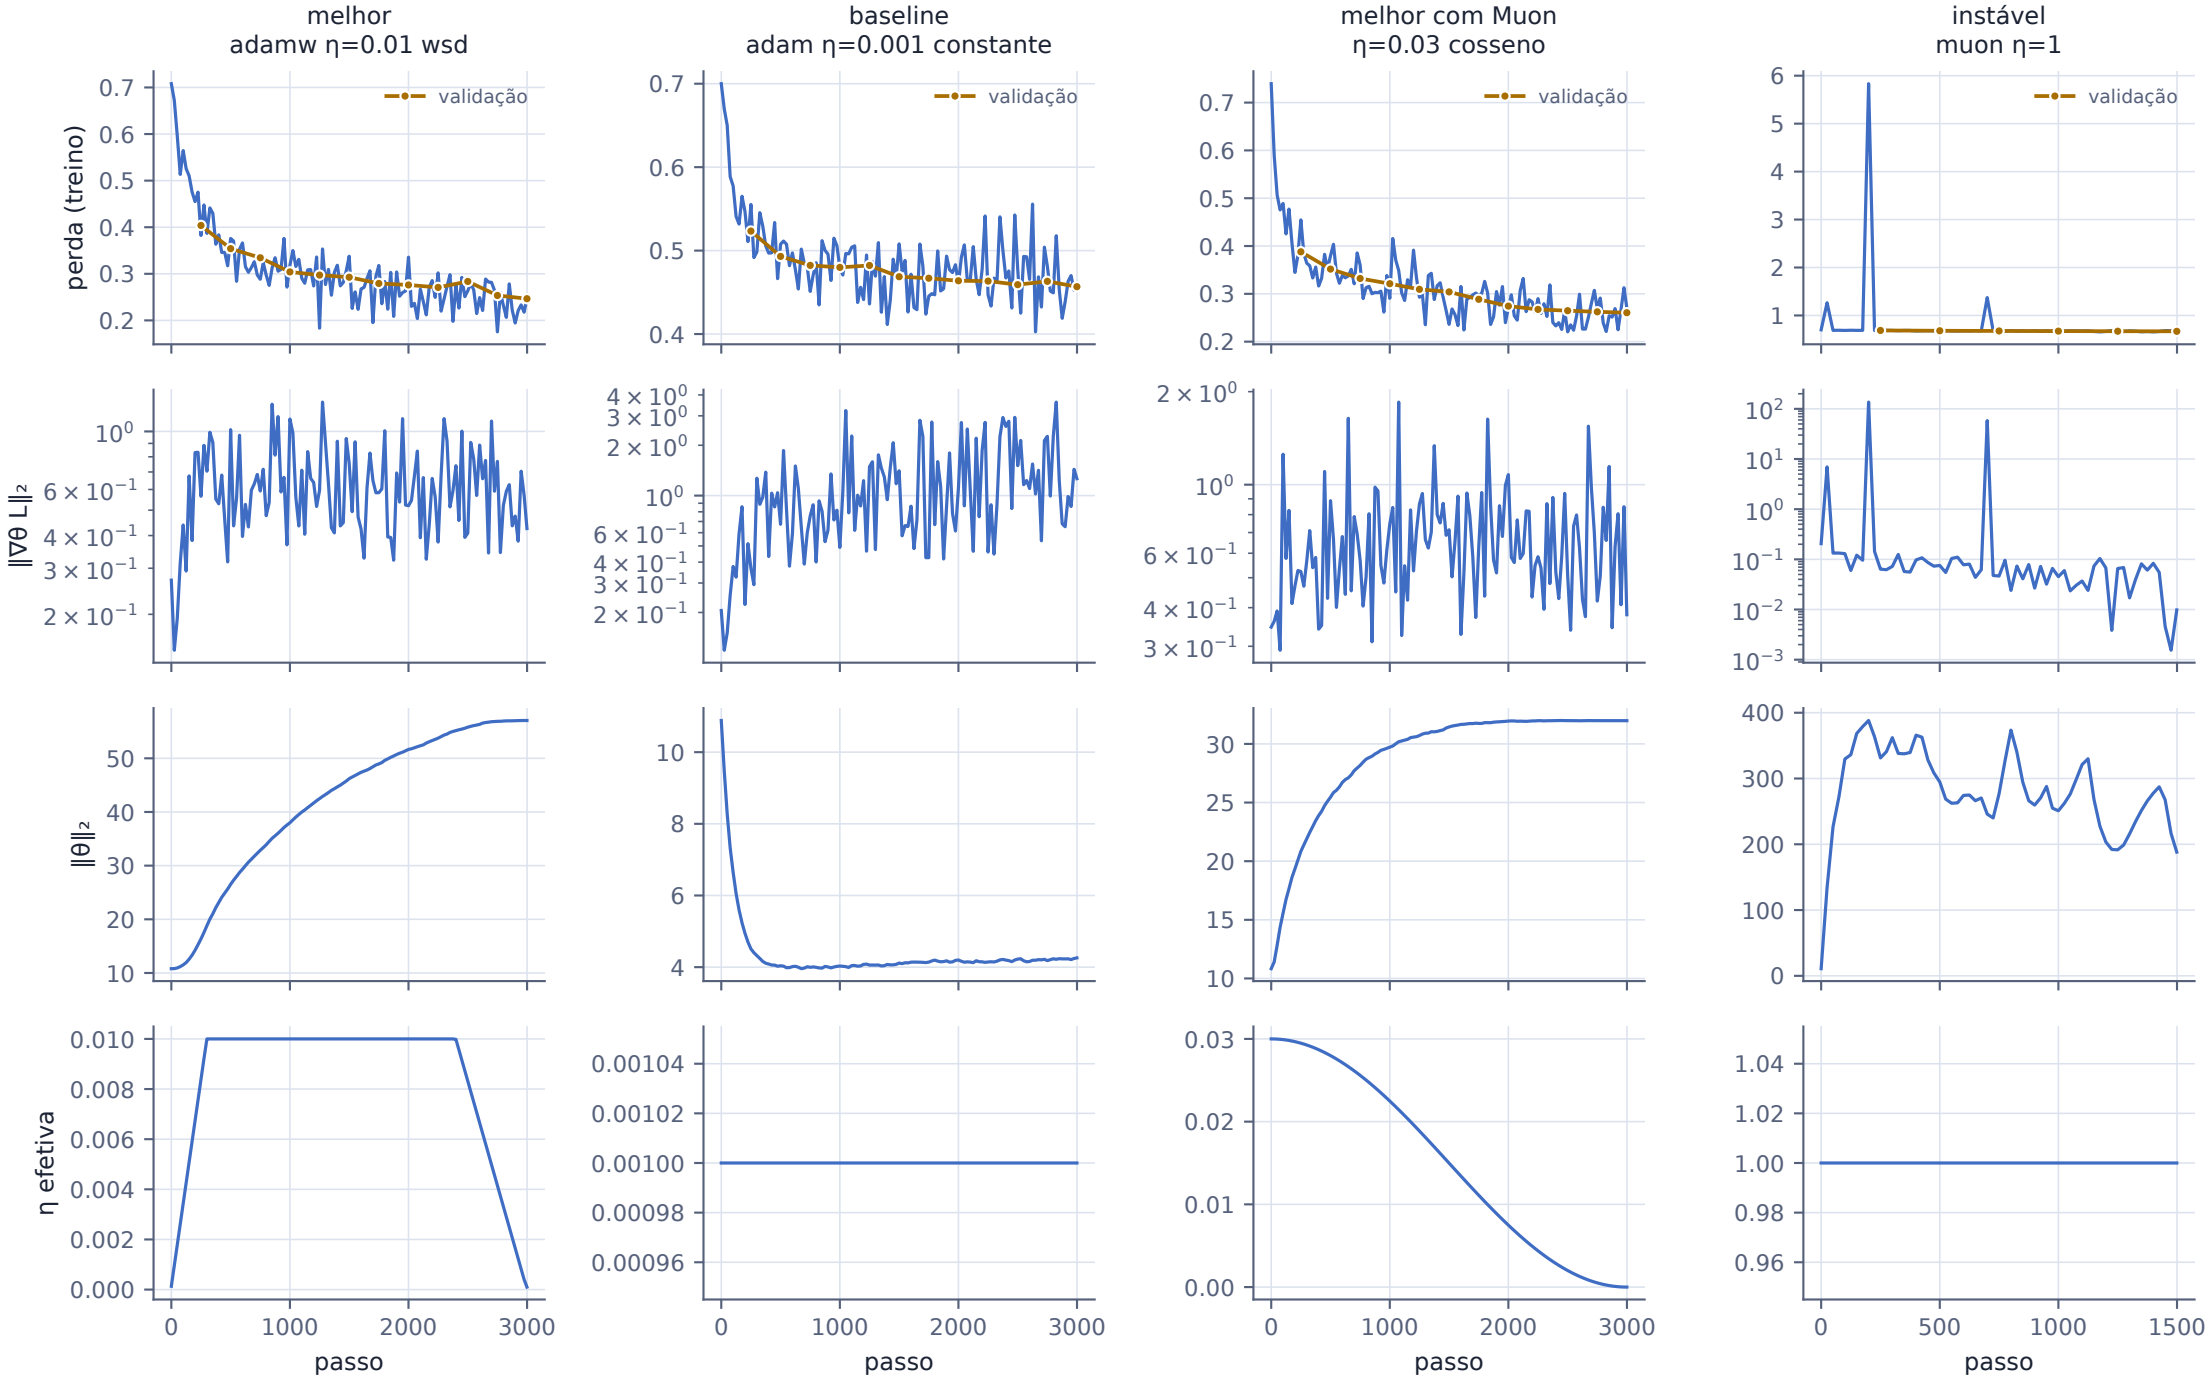
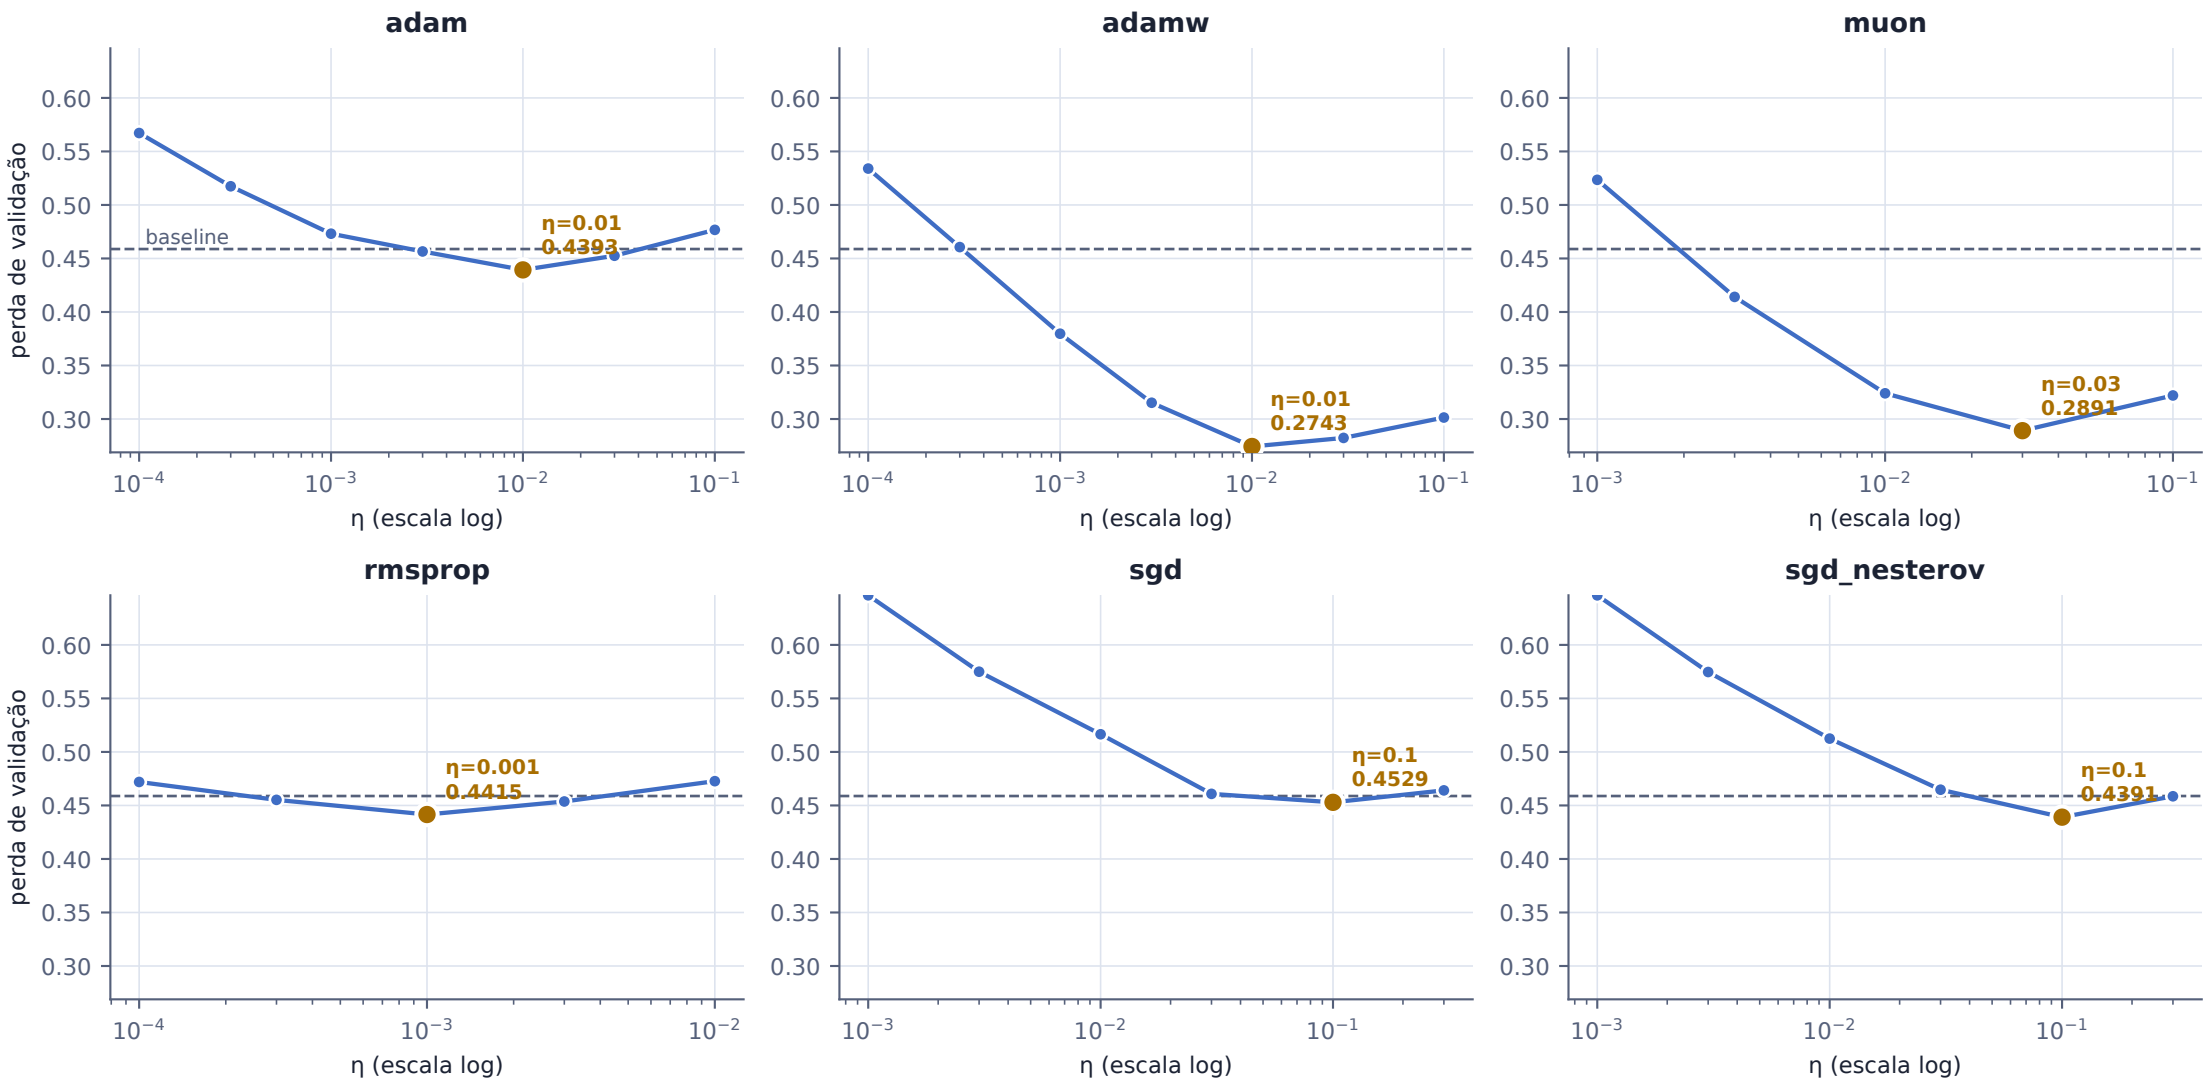
Os quatro sinais alinhados no mesmo eixo de passos

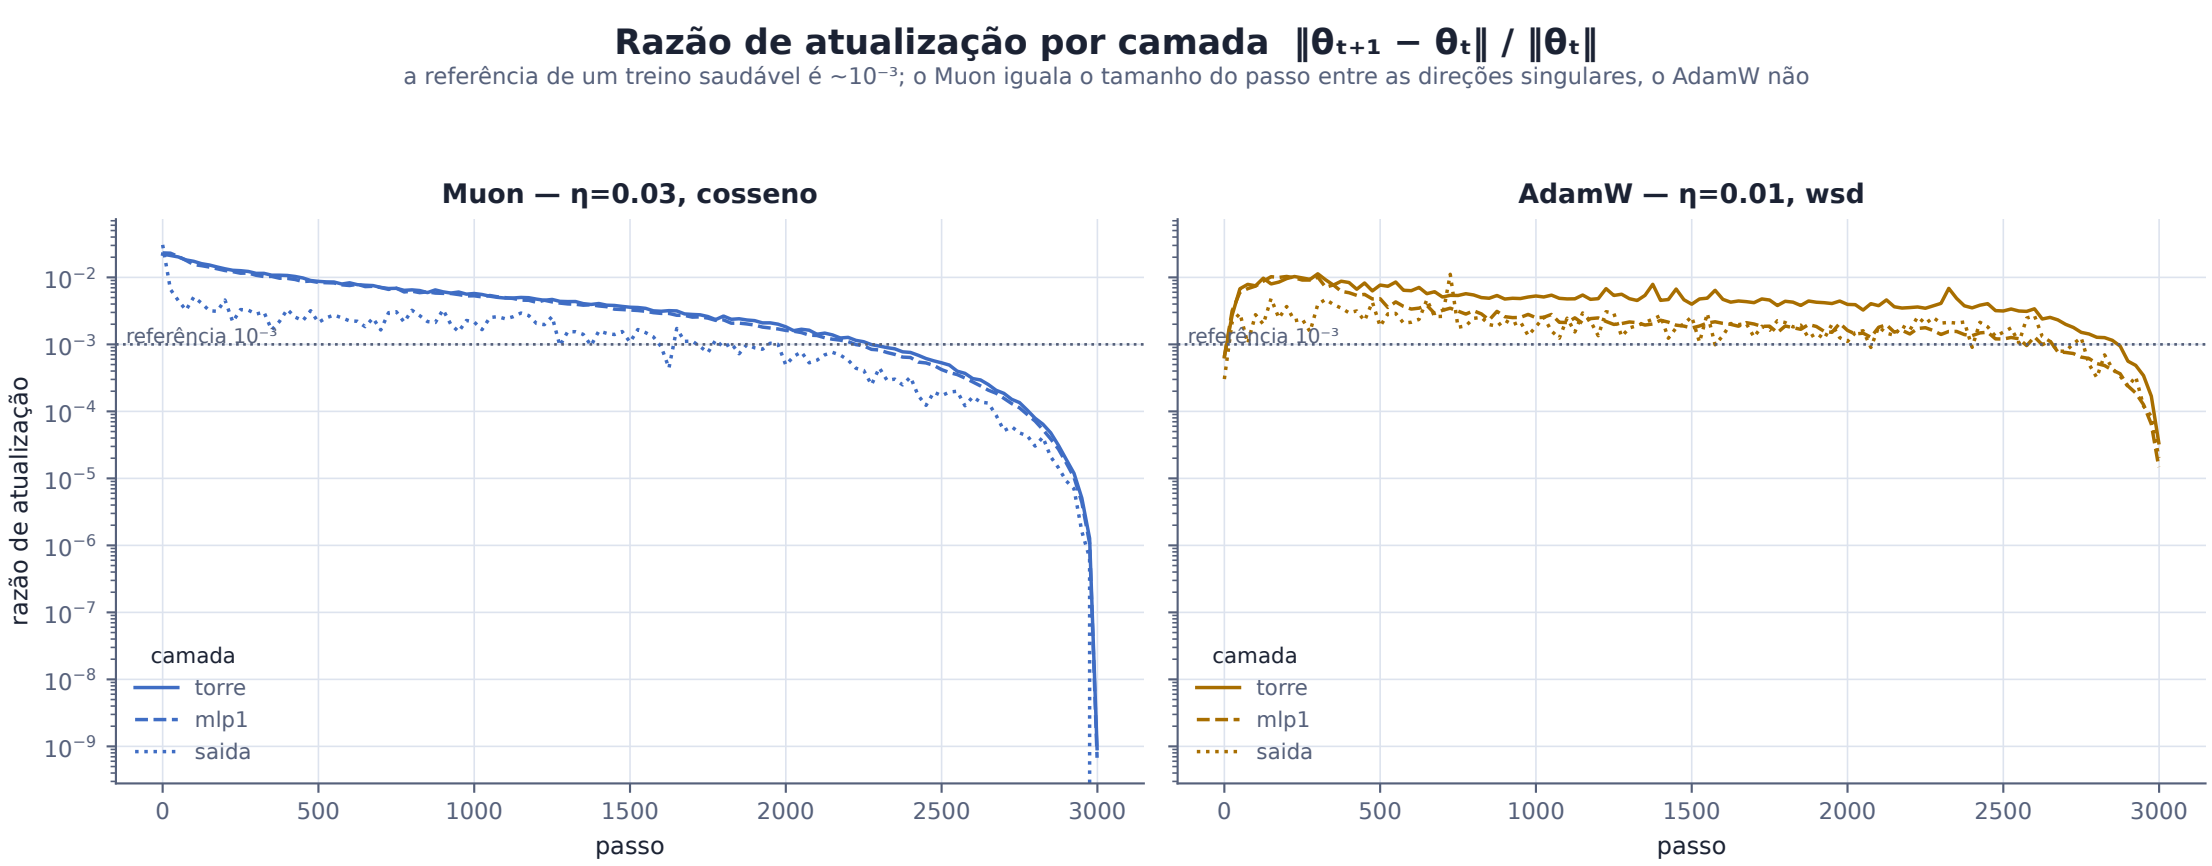
cada coluna é uma configuração; ler a mesma coluna vertical nos quatro gráficos é de onde sai o diagnóstico



Métrica de validação × η, por otimizador

pequenos múltiplos: a identidade do otimizador vem da posição, não da cor — o eixo y é comum, então as alturas se comparam entre painéis




Razão de atualização por camada ‖θ_{t+1} − θ_t‖ / ‖θ_t‖
a referência de um treino saudável é ~10⁻³; o Muon iguala o tamanho do passo entre as direções singulares, o AdamW não
Muon — η=0.03, cosseno
AdamW — η=0.01, wsd
razão de atualização
referência 10⁻³
camada
torre
mlp1
saida
passo